

UAV-YOLO：面向低空复杂场景的无人机航拍小目标检测算法及系统

陈培尧 1230922001

摘要

低空航拍图像中目标尺寸小、背景纹理复杂且遮挡密集，而机载设备又对模型规模和推理速度提出严格约束，导致通用检测器容易出现小目标漏检和背景误检。针对上述问题，本文以轻量化 YOLO11n 为基线提出 UAV-YOLO。模型采用小目标颈部结构，将浅层高分辨率定位信息与深层语义信息进行融合；同时在各尺度检测特征前引入 SCAM 空间上下文感知模块，通过全局统计与轻量卷积增强目标相关响应并抑制背景干扰。VisDrone2019 上的实验结果表明，与 YOLO11n 相比，UAV-YOLO 的参数量由 2.6M 增至 2.9M，mAP@50 由 28.40% 提升至 28.80%，mAP@50:95 由 15.40% 提升至 16.10%，小目标 mAP 由 4.37% 提升至 5.53%。模型在当前实验环境下达到 169.5 FPS，表明其在获得小目标检测收益的同时仍保持较高推理效率。本文还构建了支持多模型切换、阈值调节、类别统计和小目标分析的交互式检测系统，用于展示和分析模型输出。

关键词：无人机视觉；低空目标检测；小目标检测；YOLO11；注意力机制；VisDrone2019

1 引言

随着机载传感器、无线通信和边缘计算技术的发展，无人机凭借机动性强、部署成本低、视角灵活和覆盖范围广等特点，逐渐成为低空场景信息感知的重要平台。无人机航拍图像已广泛应用于交通监测、城市巡检、应急救援、公共安全、物流配送和农业遥感等任务。与固定监控设备相比，无人机能够快速到达复杂区域并从空中获取大范围高分辨率图像；当其与深度学习目标检测技术结合时，可以进一步实现对车辆、行人和非机动车等目标的自动定位与分类。因此，面向无人机航拍图像构建兼具精度与实时性的目标检测方法，对低空经济应用具有重要意义。

无人机航拍目标检测与普通自然图像检测存在明显差异。受飞行高度、俯视视角、相机抖动、光照变化和天气条件影响，同一目标在图像中可能表现出显著的尺度、方向和清晰度差异。VisDrone 数据集中的大量行人、车辆和自行车仅占据少量像素，并常伴随密集分布、相互遮挡和复杂道路纹理 [1]。在连续下采样过程中，小目标的边缘、轮廓和局部纹理容易被削弱，深层特征中的目标响应也可能被大面积

背景信息淹没。此外，无人机通常受到机载算力、功耗和存储空间限制，难以直接部署参数量大、计算复杂度高的检测模型。这些因素使得小目标漏检、复杂背景误检以及精度与速度难以兼顾成为低空目标检测中的主要挑战。

早期目标检测方法较多依赖人工设计特征和滑动窗口搜索，其性能容易受到尺度、光照和遮挡变化影响，难以适应复杂航拍场景。深度学习推动了目标检测方法从人工特征向端到端特征学习转变。现有检测器通常分为两阶段与单阶段两类：以 Faster R-CNN 为代表的两阶段方法先生成候选区域，再完成分类和边界框回归，具有较好的定位能力，但推理过程较长、资源消耗较大 [2]；以 SSD 和 YOLO 为代表的单阶段方法直接对目标类别和位置进行回归，在实时性方面更具优势 [3][4]。然而，单阶段检测器需要在密集位置上同时完成分类与回归，面对远距离小目标和严重遮挡时仍容易出现前景响应不足、正负样本不均衡和定位精度下降等问题。

为提高无人机图像中的小目标检测能力，现有研究主要从网络结构、多尺度特征融合和注意力建模等方面进行改进。FPN、PANet 和 BiFPN 通过融合不同层级特征，使深层语义信息与浅层空间细节形成互补 [5][6][7]。YOLO-UAV 针对复杂背景、小目标和密集遮挡问题，对 YOLOv5 的主干、特征融合网络、检测头和损失函数进行了联合改进，并通过增加高分辨率检测层增强小目标感知能力 [8]。FFCA-YOLO 和 MASF-YOLO 等方法进一步利用上下文感知、多尺度聚合和自适应融合提升遥感或无人机小目标的特征表达 [9][10]。这些方法证明了高分辨率检测分支与上下文建模的有效性，但复杂结构通常会增加参数量和计算开销，仍需在检测精度、模型规模与实时部署之间取得平衡。

近年来，YOLOv5、YOLOv8 和 YOLO11 等模型凭借较成熟的训练与部署工具链被广泛用于实时检测任务 [11][12][13]。其中，YOLO11n 具有网络结构紧凑、参数量较低和推理速度较快等优点，适合作为无人机边缘检测的基础模型。但是，原始 YOLO11n 主要在较低分辨率特征层上进行预测，浅层高分辨率信息未被充分用于检测；当目标尺寸较小或与背景对比度较低时，多次下采样会进一步削弱目标的空间细节。同时，原始网络对大范围空间上下文的利用仍然有限，容易将道路标线、屋顶纹理和密集边缘结构误判为目标。因此，如何在保持 YOLO11n 轻量化优势的同时，加强浅层细节保留和复杂背景抑制，是本文关注的核心问题。

基于上述分析，本文以 YOLO11n 为基线提出面向低空复杂场景的 UAV-YOLO。模型在颈部结构中引入面向小目标的高分辨率特征路径，将浅层定位信息与深层语义信息进行双向融合；同时在多尺度检测特征前加入 SCAM 空间上下文感知模块，通过全局池化、Softmax 和轻量卷积建立跨空间位置的上下文关系，强化目标相关响应并抑制背景干扰。本文还对 SPD 空间到深度下采样模块进行了对照实验，以分析不同细节保留策略对整体精度和小目标性能的影响。在此基础上，本文通过消融实验、先进方法对比、Grad-CAM 可视化和检测结果可视化验证所提结构，并构建交互式无人机航拍目标检测系统。主要工作如下：

- (1) 针对航拍小目标在连续下采样过程中空间细节易丢失的问题，在 YOLO11n 中引入小目标颈部结构，增加高分辨率特征路径并强化浅层定位信息与深层语义

信息的融合。

- (2) 引入轻量级 SCAM 空间上下文感知模块，利用全局统计信息和空间权重增强目标相关区域的响应，在不改变特征图分辨率的情况下抑制复杂背景干扰。
- (3) 在 VisDrone2019 数据集上完成基线模型比较、模块消融、先进方法对比和可视化分析。实验表明，UAV-YOLO 在参数量仅增加 0.3M 的情况下提升了 mAP@50:95 和小目标 mAP，实现了检测精度与模型规模之间的较好平衡。
- (4) 搭建面向无人机航拍图像的交互式目标检测系统，支持多模型切换、阈值调节、类别统计和小目标分析，为算法的实际应用与结果分析提供直观工具。

2 相关工作

2.1 基于深度学习的无人机目标检测

随着深度学习的发展，基于卷积神经网络的目标检测方法已成为无人机视觉任务的主流方案。现有检测器通常可分为两阶段和单阶段两类。两阶段方法以 Faster R-CNN 为代表，先生成候选区域再进行分类与边界框回归，具有较强的检测精度，但推理链路较长、计算开销较大 [2]。单阶段方法以 SSD 和 YOLO 系列为代表，直接回归目标类别与位置，在保持较好精度的同时具备更高实时性，更适合无人机端侧或近实时应用 [3][4]。

针对低空航拍图像中目标尺度小、背景复杂和视角变化大的特点，研究者进一步提出了多种面向无人机场景的 YOLO 改进模型。YOLOv5、YOLOv8 和 YOLO11 依托成熟的工程生态和轻量化模型族，常被作为无人机目标检测的基础框架 [11][12][13]。近期 MASF-YOLO 面向无人机视角小目标检测，在 YOLOv11 框架上引入多尺度特征聚合、改进高效多尺度注意力和自适应特征融合模块，以缓解目标像素占比小和背景干扰问题 [10]。这类工作表明，低空目标检测不仅需要较强的检测精度，也需要兼顾模型规模和推理速度。

2.2 小目标检测与多尺度特征建模

小目标检测是低空视觉任务的核心难点之一。由于深层网络在连续下采样过程中会损失细粒度空间信息，小目标在高层语义特征中容易被背景响应淹没。为此，多尺度特征融合成为提升小目标检测能力的重要思路。FPN 通过自顶向下路径和横向连接融合不同层级特征，使深层语义能够补充浅层空间细节 [5]；PANet 进一步引入自底向上的路径聚合，增强低层定位信息向高层传播的能力 [6]；EfficientDet 中的 BiFPN 则通过加权双向融合结构，在检测精度和计算效率之间进行平衡 [7]。

在上述特征金字塔思想基础上，面向遥感和航拍场景的小目标检测方法进一步强化了局部细节与全局上下文表达。例如，FFCA-YOLO 通过特征增强和上下文感知设计提升遥感小目标的局部与全局表征能力 [9]；FGPD 从目标位置分布建模角度

估计微小目标的空间先验，以改善密集小目标定位质量 [14]。这些方法说明，增加高分辨率检测分支、强化跨尺度信息交互和引入目标位置先验，都有助于缓解无人机航拍场景中的小目标漏检问题，但也可能带来额外参数量和推理开销。

2.3 注意力机制与上下文建模

为了缓解小目标特征不足与复杂背景干扰问题，注意力机制被广泛应用于目标检测任务中。SE 模块通过全局池化建立通道依赖关系，使网络能够自适应强调更重要的语义通道 [15]；CBAM 串联通道注意力与空间注意力，从两个维度对特征图进行重标定 [16]；Coordinate Attention 将位置信息嵌入通道注意力，有利于轻量化网络在保持效率的同时增强定位能力 [17]。此外，Transformer 通过自注意力机制建模长距离依赖关系，为复杂场景中的全局上下文建模提供了重要参考 [18]。

尽管注意力机制能够增强特征表达，但复杂注意力结构往往带来较高计算开销，在机载实时部署中存在一定限制。对低空航拍图像而言，模型不仅需要关注目标自身纹理，还需要利用周围道路、车辆队列和建筑边缘等上下文信息区分目标与背景。因此，本文在检测头前引入轻量级 SCAM 模块，利用全局池化、Softmax 和 1×1 卷积构建空间上下文响应，在较小参数开销下增强目标相关区域并抑制复杂背景干扰。

2.4 轻量化与实时部署方法

低空经济应用通常受到机载算力、功耗和存储空间约束，因此实时性与轻量化是无人机目标检测方法能否落地的重要因素。常见压缩策略包括网络剪枝、量化、知识蒸馏和轻量化结构设计。Deep Compression 通过剪枝、量化和 Huffman 编码显著降低神经网络存储需求，为模型压缩提供了经典范式 [19]；整数推理量化方法通过低比特整数计算减少端侧推理开销 [20]；知识蒸馏则利用教师模型的软输出指导轻量学生模型训练，以在较小模型容量下保持较好性能 [21]。

然而，轻量化模型通常面临精度下降问题，尤其是在无人机小目标检测中，过度压缩容易进一步削弱细粒度空间信息。因此，如何在有限计算资源下同时保持高分辨率小目标特征、有效上下文建模和较低参数量，仍是当前低空目标检测研究的核心挑战。本文选择轻量化 YOLO11n 作为基线，在颈部结构和注意力模块上进行局部增强，目标是在参数量增长有限的情况下提升小目标召回和定位质量。

3 UAV-YOLO 方法

3.1 总体结构

UAV-YOLO 以 YOLO11n 为基础框架，由主干网络、颈部网络和检测头三部分组成。主干网络提取多层次特征，颈部网络完成跨尺度特征聚合，检测头输出类别、置信度和边界框。本文的结构设计围绕两个相互关联的问题展开：针对连续下采样

造成的小目标细节损失，采用小目标颈部结构引入高分辨率检测路径；针对复杂背景造成的响应扩散，在 H2、H3、H4 和 H5 四个检测尺度前加入 SCAM 模块。

UAV-YOLO 的总体结构如图 1 所示。模型保留 YOLO11n 的轻量化主干，在颈部网络中利用上采样、拼接和 C3k2 模块构建双向多尺度特征流。小目标颈部负责补充高分辨率空间信息，SCAM 则在特征送入检测头前进行上下文重标定。两项改动分别对应“保留目标细节”和“抑制背景干扰”，避免将多个结构变化表述为彼此独立的改进点。




图 1: UAV-YOLO 总体结构图

设输入图像大小为 640×640 。原始 YOLO11n 在 80×80 、 40×40 和 20×20 三个尺度上进行检测，本文分别记为 H3、H4 和 H5。UAV-YOLO 额外引入 160×160 的 H2 检测特征，以保留更细粒度的位置信息。最终检测头接收四个尺度的特征图：

$$\{F_{H2}, F_{H3}, F_{H4}, F_{H5}\}.$$

3.2 小目标颈部结构

低空航拍图像中的行人和车辆往往仅占据少量像素。若仅使用深层低分辨率特征，小目标的边缘和位置信息会在连续下采样后被削弱。为此，UAV-YOLO 将原有颈部替换为面向小目标的多尺度颈部，通过融合浅层特征与上采样后的高层语义特征，生成 H2 高分辨率检测特征。

具体而言，模型在原始 H3 分支之前继续上采样，并与主干网络中的 P2 特征融合，再通过 C3k2 模块整合语义与空间信息。如图 2 所示，H2 分支形成高分辨率输出；随后，自底向上的下采样路径将其细粒度定位信息逐级传递至 H3、H4 和 H5。主干网络的 P3、P4 特征还以残差连接方式输入 D1、D2 层，以缩短信息传播路径。该结构的目标不是单纯增加检测尺度，而是在多尺度融合过程中持续保留小目标的纹理和边缘线索。




图 2: 小目标颈部结构图

3.3 SCAM 空间上下文感知模块

小目标颈部增强了高分辨率细节，但局部卷积仍可能对道路标线、建筑边缘等高频背景产生较强响应。为在检测前利用更大范围的上下文约束，本文在各检测尺度前加入 SCAM，使目标区域的局部响应能够结合全局统计信息进行重新加权。

SCAM 的具体结构如图 3 所示。输入特征首先被送入全局信息提取分支，该分支并行采用全局平均池化和全局最大池化，从整体响应分布和显著响应两个角度提取全局描述，再通过 Softmax 形成归一化的上下文权重。与此同时，输入特征还经过两条 1×1 的 CBS 分支生成轻量化特征表示：上方 CBS 分支与全局上下文权重相乘，用于引入跨空间位置的全局约束；下方 CBS 分支经 Softmax 后与该全局约束结果再次相乘，进一步筛选与目标区域更相关的空间响应。最后，模块通过 1×1 CBS 和 1×1 卷积对上下文增强后的特征进行整合，并利用 Sigmoid 生成门控权重，对输出特征进行重标定。通过这种方式，SCAM 能够在较小计算开销下强化目标相关区域，同时削弱道路纹理、建筑边缘等复杂背景带来的干扰。




图 3: 空间上下文感知模块结构图

给定第 i 个检测尺度上的输入特征 $P_i \in \mathbb{R}^{C \times H \times W}$ ，SCAM 可简化表示为

$$Q_i = P_i \otimes \sigma(G_i),$$

其中 Q_i 为输出特征， G_i 表示由全局信息分支与两条 CBS 分支共同生成的上下文增强特征， $\sigma(\cdot)$ 表示 Sigmoid 函数， $\otimes$ 表示逐元素乘法。该模块不改变特征图分辨率，主要依赖池化、Softmax、 1×1 卷积和门控重标定完成上下文建模，适合嵌入到轻量化检测头前。

3.4 空间到深度模块 (Space to Depth Module, SPD)

实验过程中还尝试了 SPD 下采样思想，其结构如图 4 所示。SPD 通过空间重排的方式将局部邻域像素搬移到通道维度，理论上能够减少直接步长下采样造成的细节损失，对小目标保留具有一定潜力。




图 4: SPD 下采样模块结构图

消融结果显示，单独使用 SPD 后，小目标 mAP 略有提升且参数量下降，但 mAP@50 和 mAP@50:95 同时降低。这表明空间重排可能保留了部分局部细节，却未在当前网络配置中形成更好的综合检测性能。由于现有实验尚不能确定性能下降的唯一原因，本文不对其作单一机制归因。基于综合指标，SPD 仅作为对照分支进行讨论，最终 UAV-YOLO 保留小目标颈部结构与 SCAM 的组合。

4 实验设置

4.1 数据集与评价指标

本文采用 VisDrone2019 数据集进行实验。该数据集由无人机平台采集，包含多种城市道路、广场、居民区和复杂交通场景，目标类别包括行人、车辆、自行车等典型低空目标 [1]。由于图像中小目标比例较高，VisDrone2019 能够较好检验模型在低空航拍场景下的检测能力。

评价指标包括 mAP@50、mAP@50:95、小目标平均精度 (mAPs)、参数量和推理效率。mAP@50 反映 IoU 阈值为 0.5 时的检测能力；mAP@50:95 对多个 IoU 阈值下的平均精度取均值，更严格地衡量分类与定位质量；mAPs 用于评估模型对小尺度目标的检测能力。参数量、权重大小、单图推理时间和 FPS 用于刻画模型规模与实时性。

4.2 训练配置

实验基于 PyTorch 框架实现 [22]。为保证比较的一致性，各模型采用相同的数据划分、训练轮次、输入尺寸和主要优化配置，具体参数见表 1。

表 1: 实验超参数设置

超参数项目	设置数值
训练轮次	300
初始学习率	0.001
优化器	SGD
输入尺寸	640×640
批次大小	8

5 实验结果与分析

5.1 消融实验

表 2 比较了不同结构配置。单独使用 SPD 时，参数量由 2.6M 降至 2.2M，mAPs 由 4.37% 升至 4.58%，但 mAP@50 和 mAP@50:95 分别降至 27.60% 和 15.10%，说明局部细节收益不足以抵消整体检测性能下降。单独加入小目标颈部后，mAP@50 保持 28.40%，mAP@50:95 提升至 15.80%，mAPs 提升至 5.53%，表明高分辨率路径主要改善了更严格定位条件和小尺度目标检测。单独加入 SCAM 后，mAP@50 为 27.70%，mAP@50:95 和 mAPs 分别为 15.50% 和 4.60%；其单模块收益有限，但为与小目标颈部的互补组合提供了依据。

小目标颈部与 SCAM 联合使用时取得最佳综合结果：mAP@50、mAP@50:95 和 mAPs 分别达到 28.80%、16.10% 和 5.53%，参数量为 2.9M。相较 YOLO11n，最终模型仅增加 0.3M 参数，mAP@50:95 和 mAPs 分别提高 0.70 和 1.16 个百分点。结果支持两项设计的分工：小目标颈部提供主要的细节保留收益，SCAM 在此基础上进一步改善综合定位质量。

表 2: UAV-YOLO 模块消融实验

空间-深度	小目标颈部	全局信息	mAP@50	mAP@50:95	mAPs	参数量
—	—	—	28.40%	15.40%	4.37%	2.6M
✓	—	—	27.60%	15.10%	4.58%	2.2M
—	✓	—	28.40%	15.80%	5.53%	2.7M
—	—	✓	27.70%	15.50%	4.60%	2.8M
—	✓	✓	28.80%	16.10%	5.53%	2.9M
较 YOLO11n			+0.40%	+0.70%	+1.16%	+0.3M

为观察特征关注区域的变化，本文对 YOLO11n 与 UAV-YOLO 进行 Grad-CAM 可视化，如图 5 所示。在三个样例中，YOLO11n 的高响应区域更容易向复

杂纹理和目标周边扩散，而 UAV-YOLO 的响应相对集中于真实目标及其邻近区域。该定性结果与消融实验趋势一致：H2 高分辨率路径提供更细粒度的空间线索，SCAM 对上下文响应进行重标定。




图 5: Grad-CAM 可视化对比，其中越红表示模型关注度越高，越蓝表示模型关注度越低。

表 3 比较了 YOLO11n 与 UAV-YOLO 的模型规模和推理效率。UAV-YOLO 的参数量和权重大小分别增加 0.3M 和 0.3MB，单图推理时间由 1.6ms 增至 2.2ms，FPS 由 200 降至 169.5。尽管结构增强带来一定速度代价，模型在当前实验环境下仍保持较高帧率，说明其具备进一步开展边缘设备实测的潜力。

表 3: YOLO11n 与 UAV-YOLO 的模型规模和推理效率对比

模型	参数量	权重大小	推理时间	FPS
YOLO11n	2.6M	5.4MB	1.6ms	200
UAV-YOLO	2.9M	5.7MB	2.2ms	169.5

5.2 与先进方法对比

表 4 给出了 UAV-YOLO 与表列模型的比较。L-FFCA-YOLO [9] 的 mAP@50 和 mAPs 较高，但参数量达到 5.1M；YOLO11n+SOD 参考微小目标位置分布建模思想 [14]，mAPs 略高于 UAV-YOLO，但参数量为 3.7M。UAV-YOLO 以 2.9M 参数取得表列结果中最高的 mAP@50:95，说明其优势主要体现在严格 IoU 条件下的综合定位质量与模型规模平衡，而非在每一项指标上均占优。

表 4: UAV-YOLO 与相关模型的性能对比

模型	mAP@50	mAP@50:95	小目标 mAP	参数量
YOLOv5n	27.50%	14.80%	4.21%	2.5M
YOLOv8n	27.90%	15.10%	4.36%	3.2M
YOLO11n	28.40%	15.40%	4.37%	2.6M
L-FFCA-YOLO [9]	29.30%	15.80%	5.81%	5.1M
YOLO11n+SOD [14]	28.70%	15.70%	5.67%	3.7M
UAV-YOLO	28.80%	16.10%	5.53%	2.9M

图 6 给出了不同模型在三个典型低空航拍样例上的检测结果。整体来看, YOLOv8n 和 YOLO11n 在远距离小目标、密集行人和复杂道路纹理中容易出现漏检。文献方法 [9][14] 能够提升部分小目标的召回。UAV-YOLO 在保持较小参数数量的同时, 对小尺度目标的覆盖较为完整, 在密集目标和复杂背景并存的区域表现较均衡。该可视化结果与表 4 中 UAV-YOLO 在 mAP@50:95 上取得较好结果的趋势一致, 说明其改进并非只提升低 IoU 阈值下的粗略召回, 而是对定位质量也有一定帮助。




图 6: 不同模型在三个典型样例上的检测结果对比, 其中绿色框代表TP, 黄色框代表FP, 红色框代表FN。

6 检测系统设计

为将模型评估结果转化为可交互的分析流程, 本文构建了基于 UAV-YOLO 的无人机航拍小目标检测系统, 其结构如图 7 所示。系统采用输入、控制、推理、分析和展示五层结构: 输入层负责读取 jpg、jpeg 和 png 图像; 控制层提供模型选择、置信度阈值、IoU 阈值和推理尺寸设置; 推理层统一调用 UAV-YOLO、YOLOv5n、YOLOv8n 和 YOLO11n; 分析层统计目标总数、小目标数量和类别分布; 展示层呈

现原图、检测框、结果明细和统计图。分层设计使模型推理与结果分析解耦，便于在相同输入和参数条件下比较不同模型。




图 7: 检测系统结构图

该系统主要服务于模型展示和误差分析。多模型切换支持同图比较；阈值调节与局部放大便于检查低置信度目标和密集区域；类别统计及小目标筛选则将检测框结果转化为可读的分析信息。当前系统验证了算法从推理到交互展示的完整流程，但尚未包含真实无人机视频流接入、设备功耗监控和端侧部署测试。

7 结论与展望

本文针对无人机航拍图像中的小目标细节损失、复杂背景干扰和轻量化约束，提出基于 YOLO11n 的 UAV-YOLO。小目标颈部通过 H2 高分辨率路径保留浅层定位信息，SCAM 在检测前利用空间上下文对特征响应进行重标定。VisDrone2019 实验表明，相较 YOLO11n，UAV-YOLO 的参数量由 2.6M 增至 2.9M，mAP@50、mAP@50:95 和 mAPs 分别提高 0.40、0.70 和 1.16 个百分点；模型在当前实验环境下达到 169.5 FPS。消融结果进一步表明，小目标颈部提供主要的小尺度检测收益，SCAM 与其组合后改善了综合定位质量。上述结果支持本文的核心判断：在有限参数增长下，细节保留与背景上下文建模具有互补作用。

本文仍存在三方面限制。首先，实验主要基于 VisDrone2019，尚不足以说明模型在夜间、雨雾、强光和跨数据集场景中的泛化能力。其次，Grad-CAM 和检测样例提供了定性解释，但尚缺少按目标尺寸、遮挡程度和背景复杂度划分的系统误差分析。最后，当前实时性数据来自既有实验环境，尚未在实际嵌入式平台上测量端侧延迟、功耗和内存占用。后续工作将扩充复杂天气与跨域数据，开展分场景误差统计，并在边缘设备上验证量化、推理加速和持续视频检测性能，从而进一步评估 UAV-YOLO 的实际部署价值。

参考文献

- [1] P. Zhu, L. Wen, X. Bian, H. Ling, and Q. Hu, “Vision meets drones: A challenge,” *arXiv preprint arXiv:1804.07437*, 2018. [Online]. Available: <https://arxiv.org/abs/1804.07437>
- [2] S. Ren, K. He, R. Girshick, and J. Sun, “Faster R-CNN: Towards real-time object detection with region proposal networks,” *IEEE Transactions on Pattern Analysis and Machine Intelligence*, vol. 39, no. 6, pp. 1137–1149, 2017. [Online]. Available: <https://doi.org/10.1109/TPAMI.2016.2577031>
- [3] W. Liu, D. Anguelov, D. Erhan, C. Szegedy, S. Reed, C.-Y. Fu, and A. C. Berg, “SSD: Single shot multibox detector,” in *Computer Vision – ECCV 2016*. Springer, 2016, pp. 21–37. [Online]. Available: https://doi.org/10.1007/978-3-319-46448-0_2
- [4] J. Redmon and A. Farhadi, “YOLOv3: An incremental improvement,” *arXiv preprint arXiv:1804.02767*, 2018. [Online]. Available: <https://arxiv.org/abs/1804.02767>
- [5] T.-Y. Lin, P. Dollár, R. Girshick, K. He, B. Hariharan, and S. Belongie, “Feature pyramid networks for object detection,” in *2017 IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*. IEEE, 2017, pp. 936–944. [Online]. Available: <https://doi.org/10.1109/CVPR.2017.106>
- [6] S. Liu, L. Qi, H. Qin, J. Shi, and J. Jia, “Path aggregation network for instance segmentation,” in *2018 IEEE/CVF Conference on Computer Vision and Pattern Recognition*. IEEE, 2018, pp. 8759–8768. [Online]. Available: <https://doi.org/10.1109/CVPR.2018.00913>
- [7] M. Tan, R. Pang, and Q. V. Le, “EfficientDet: Scalable and efficient object detection,” in *2020 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*. Seattle, WA, USA: IEEE, 2020, pp. 10 778–10 787. [Online]. Available: <https://doi.org/10.1109/CVPR42600.2020.01079>
- [8] C. Ma, Y. Fu, D. Wang, R. Guo, X. Zhao, and J. Fang, “YOLO-UAV: Object detection method of unmanned aerial vehicle imagery based on efficient multi-scale feature fusion,” *IEEE Access*, vol. 11, pp. 126 857–126 878, 2023. [Online]. Available: <https://doi.org/10.1109/ACCESS.2023.3329713>
- [9] Y. Zhang, M. Ye, G. Zhu, Y. Liu, P. Guo, and J. Yan, “FFCA-YOLO for small object detection in remote sensing images,” *IEEE Transactions on Geoscience*

- and Remote Sensing*, vol. 62, pp. 1–15, 2024, art. no. 5611215. [Online]. Available: <https://doi.org/10.1109/TGRS.2024.3363057>
- [10] L. Lu, D. He, C. Liu, and Z. Deng, “MASF-YOLO: An improved YOLOv11 network for small object detection on drone view,” *arXiv preprint arXiv:2504.18136*, 2025. [Online]. Available: <https://arxiv.org/abs/2504.18136>
 - [11] G. Jocher, “Ultralytics YOLOv5,” 2020. [Online]. Available: <https://github.com/ultralytics/yolov5>
 - [12] G. Jocher, A. Chaurasia, and J. Qiu, “Ultralytics YOLOv8,” 2023. [Online]. Available: <https://github.com/ultralytics/ultralytics>
 - [13] G. Jocher and J. Qiu, “Ultralytics YOLO11,” 2024. [Online]. Available: <https://github.com/ultralytics/ultralytics>
 - [14] J. Bian, M. Feng, W. Dong, F. Wu, J. Luo, Y. Wang, and G. Shi, “Feature information driven position gaussian distribution estimation for tiny object detection,” in *2025 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*. Nashville, TN, USA: IEEE, 2025, pp. 30 376–30 386. [Online]. Available: <https://doi.org/10.1109/CVPR52734.2025.02828>
 - [15] J. Hu, L. Shen, and G. Sun, “Squeeze-and-excitation networks,” in *2018 IEEE/CVF Conference on Computer Vision and Pattern Recognition*. IEEE, 2018, pp. 7132–7141. [Online]. Available: <https://doi.org/10.1109/CVPR.2018.00745>
 - [16] S. Woo, J. Park, J.-Y. Lee, and I. S. Kweon, “CBAM: Convolutional block attention module,” in *Computer Vision – ECCV 2018*. Springer, 2018, pp. 3–19. [Online]. Available: https://doi.org/10.1007/978-3-030-01234-2_1
 - [17] Q. Hou, D. Zhou, and J. Feng, “Coordinate attention for efficient mobile network design,” in *2021 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*. IEEE, 2021, pp. 13 708–13 717. [Online]. Available: <https://doi.org/10.1109/CVPR46437.2021.01350>
 - [18] A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A. N. Gomez, L. Kaiser, and I. Polosukhin, “Attention is all you need,” in *Advances in Neural Information Processing Systems*, vol. 30, 2017. [Online]. Available: https://proceedings.neurips.cc/paper_files/paper/2017/hash/3f5ee243547dee91fbd053c1c4a845aa-Abstract.html
 - [19] S. Han, H. Mao, and W. J. Dally, “Deep compression: Compressing deep neural networks with pruning, trained quantization and huffman coding,” in

- International Conference on Learning Representations*, 2016. [Online]. Available: <https://openreview.net/forum?id=n4Bp24yb5L>
- [20] B. Jacob, S. Kligys, B. Chen, M. Zhu, M. Tang, A. Howard, H. Adam, and D. Kalenichenko, “Quantization and training of neural networks for efficient integer-arithmetic-only inference,” in *2018 IEEE/CVF Conference on Computer Vision and Pattern Recognition*. IEEE, 2018, pp. 2704–2713. [Online]. Available: <https://doi.org/10.1109/CVPR.2018.00286>
- [21] G. Hinton, O. Vinyals, and J. Dean, “Distilling the knowledge in a neural network,” in *NIPS Deep Learning and Representation Learning Workshop*, 2015. [Online]. Available: <https://research.google/pubs/distilling-the-knowledge-in-a-neural-network/>
- [22] A. Paszke, S. Gross, F. Massa, A. Lerer, J. Bradbury, G. Chanan, T. Killeen, Z. Lin, N. Gimelshein, L. Antiga, A. Desmaison, A. Kopf, E. Yang, Z. DeVito, M. Raison, A. Tejani, S. Chilamkurthy, B. Steiner, L. Fang, J. Bai, and S. Chintala, “PyTorch: An imperative style, high-performance deep learning library,” in *Advances in Neural Information Processing Systems*, vol. 32, 2019. [Online]. Available: https://papers.neurips.cc/paper_files/paper/2019/hash/bdbca288fee7f92f2bfa9f7012727740-Abstract.html